

文本分类实验报告

自然语言处理课程作业一 NYT 新闻分类

姓名：何熹淳 学号：2410721

运行状态：全部七组实验已有实测结果。

一 实验目的与数据

比较词袋表示、平均词向量和预训练 BERT 在同一 NYT 新闻分类任务中的效果。线性模型统一使用 Logistic Regression；BERT 对分类任务进行全参数微调。所有报告指标都由本次运行保存的测试预测计算，缺失实验不填入推测数值。

数据	规模	用途
NYT	11,519 篇，3 类	监督分类、训练集 Word2Vec
AG News	90,000 篇	无监督训练 Word2Vec

类别	总计	训练	验证	测试
business	1429	1143	143	143
politics	1451	1161	145	145
sports	8639	6911	864	864
合计	11519	9215	1152	1152

固定 seed=42，采用分层随机打乱，先划分 80% 训练集与 20% 留出集，再把留出集均分为验证集和测试集。整数取整后为 9,215 / 1,152 / 1,152。保存原始行号和数据 SHA-256，所有实验读取同一份 splits.json。

体育类占 75.00%。在测试集全部预测 sports 的多数类基线 Accuracy=75.00%，Macro-F1=28.57%，因此不能只凭准确率评价模型。数据没有空文本或空标签，但有 72 条标准化重复文本；跨集合重复的影响在第四节单独检查。

任务解释：要求文档写“三种”词袋方法，却只列出 Binary 与 Word Frequency。本实验补充 TF-IDF 作为第三种，属于明确假设，提交前可向教师确认。

二 方法与训练设置

词袋与词向量统一把英文转小写，使用正则提取英文单词、词内单引号及数字，不去停用词。BERT 直接对原始文本使用其预训练 tokenizer。词表、IDF 以及 NYT Word2Vec 均仅从训练集学习，验证集用于选择参数，测试集只用于最终评价。

方法	文档表示与设置
Binary BOW	每个词出现记为 1，否则为 0。保留训练集完整词表。
Word Frequency	每个维度表示该词在文档中的原始出现次数。
TF-IDF	tf 为原始词频；idf=log((1+N)/(1+df))+1；再作 L2 归一化。
GloVe	glove.6B.100d，使用预训练 100 维词向量。
Word2Vec AG / NYT	分别在全部 AG 或仅 NYT 训练集训练。Skip-gram，100 维，window=5，min_count=2，negative=5，10 epochs，单线程。
BERT	google-bert/bert-base-uncased；max_length=64；完整 3 epochs；全参数微调。

词向量文档表示为所有有效词向量的算术平均，重复出现的词按出现次数参与平均。OOV 词忽略，分母为实际命中词的数量；若没有有效词则使用 100 维零向量。每个划分的词覆盖率和零向量文档数保存在结果 JSON。

Logistic Regression 使用 L2 正则、lbfgs 和 max_iter=2000，在 $C=\{0.1, 1, 10\}$ 中按验证集 Macro-F1 选最优值，相同时优先较小 C。选择后不合并验证集重训。

BERT 代码采用 AdamW，学习率 $2e-5$ ，weight_decay=0.01，batch size 默认 16，10% warmup 后线性衰减，梯度范数裁剪为 1。每轮评估验证集，完整训练三轮后载入验证 Macro-F1 最高的一轮，最后评测测试集。

三 评价指标

Accuracy 为正确预测数除以测试样本数。对每个类别 k ， $F1(k)=2TP(k)/(2TP(k)+FP(k)+FN(k))$ ；Macro-F1 是三个类别 F1 的算术平均，分母为零时对应 F1 设为 0。Macro-F1 对每个类别等权，能反映少数类别表现。

实现未对类别设置不同权重；此处的类别不均衡由分层划分、Macro-F1 和逐类指标揭示。本实验是单个固定种子的比较，不能把小幅差异解释为统计显著优势。

四 实测结果与复核

模型	测试 Accuracy	测试 Macro-F1	选定 C / 轮次
Binary BOW	98.87%	97.26%	0.1
Word Frequency	98.96%	97.51%	10.0
TF-IDF	99.22%	98.11%	10.0
GloVe 100d	98.52%	96.46%	1.0
Word2Vec AG	97.83%	94.60%	10.0
Word2Vec NYT	98.87%	97.18%	10.0
BERT-base-uncased	97.83%	95.11%	3

本次划分下，TF-IDF 的测试 Macro-F1 最高，为 98.11%。排序仅代表本次单种子实验。

Binary 与词频模型保留了直接区分类别的词汇信息。TF-IDF 减弱高文档频率词的权重，可能使主题词更突出。平均词向量把整篇文档压缩到 100 维，降低存储维度，但丢失词序且可能稀释强分类信号；这些是方法层面的解释，并非经过消融验证的因果结论。

AG 与 NYT 自训练词向量的测试 Macro-F1 分别为 94.60% 和 97.18%。语料规模与领域匹配同时发生变化，不能只把差异归因于其中一个因素。

BERT 被要求截断到 64 个 token，而传统方法读取全文。比较同时包含表示方式与可见文本长度的差别；即使 BERT 完成，也不应把性能差异完全归因于模型结构。

实际分词审计显示，测试集 1,152 / 1,152 篇新闻均超过 64 个 token，原文 token 长度中位数为 888.5，90 分位数为 1242.8。这说明 BERT 的输入覆盖远短于词袋模型，是解释结果时必须考虑的限制。

重复文本敏感性

标准化方式为小写并合并连续空白。训练/验证、训练/测试、验证/测试分别存在 14、10、1 个重叠文本。保留课程要求的原始随机划分作为主结果，再仅从测试评价中排除与训练文本重叠的 10 条，剩余 1,142 条，不重新训练或调参。

模型	原 Macro-F1	排除重叠后 Macro-F1
Binary BOW	97.26%	97.22%
Word Frequency	97.51%	97.47%
TF-IDF	98.11%	98.08%
GloVe 100d	96.46%	96.40%
Word2Vec AG	94.60%	94.50%
Word2Vec NYT	97.18%	97.14%
BERT-base-uncased	95.11%	95.02%

五 错误分析与可复现性

以下展示当前最佳已完成模型 TF-IDF 的混淆矩阵。行是真实类别，列是预测类别；类别顺序保持 business、politics、sports。

真实 / 预测	business	politics	sports
business	140	2	1
politics	5	140	0
sports	1	0	863

类别	Precision	Recall	F1
business	95.89%	97.90%	96.89%
politics	98.59%	96.55%	97.56%
sports	99.88%	99.88%	99.88%

以 TF-IDF 的错误为例：原始行号 995（零起始）讨论伦敦奥运会的经济收益，真实类别 sports，预测 business；行号 5358 讨论参议院学生贷款利率协议，真实类别 politics，预测 business。两篇同时涉及体育或政治事件与经济术语，说明类别边界可能交叉；这属于文本内容观察，不等同于已证明模型的具体决策原因。

BERT 完整训练三轮，各轮验证 Macro-F1 依次为 93.03%、94.91%、95.03%；按预定规则选第 3 轮，在测试集得到 95.11%。

verify_results.py 使用 Python 标准库独立计数 TP、FP、FN，复算所有已完成模型的 Accuracy 和 Macro-F1，并断言结果与保存 JSON 一致、测试行号顺序一致、真实标签一致、三集合行号互斥且覆盖全体样本。检查结果保存在 verification.json。

复现与交付

从 README.md 安装依赖；依次执行词袋、Word2Vec、GloVe 和 BERT 命令，再执行 verify_results.py 与 build_report.py。模型结果、测试逐条预测与固定划分均包含在 results 中。预训练大权重通过下载脚本或 Hugging Face 获取，不放入 GitHub 普通文件。

复现限制：不同库版本、CPU/GPU 运算与浮点精度可能产生合理差异。固定单线程 Word2Vec 和随机种子降低随机性，但不承诺跨平台逐位一致。重复敏感性检查仅覆盖完全相同的标准化文本，不排除近重复或语义相似内容。

参考资料

1. 课程提供的《作业一要求》与 nyt.csv、ag.csv。
2. Stanford GloVe: <https://nlp.stanford.edu/projects/glove/>
3. BERT: <https://huggingface.co/google-bert/bert-base-uncased>
4. GloVe 下载镜像: huggingface.co/datasets/SLU-CSCI4750/glove.6B.100d.txt。解压文件 SHA-256 见 README.md。